

논문 2015-52-6-16

웨어러블 가속도 기기 측정에 의한 수면/비수면 동적 분류

(Sleep/Wake Dynamic Classifier based on Wearable Accelerometer Device Measurement)

박 재 현*, 김 대 훈*, 구 본 화**, 고 한 석***

(Jaihyun Park, Daehun Kim, Bonhwa Ku, and Hanseok Ko[©])

요 약

최근 현대인들의 스트레스 증가로 인하여 수면 장애에 대한 문제가 부각되면서 수면의 질에 대한 관심이 급증하고 있다. 이러한 수면 장애는 정밀한 진단을 위해서 긴 시간과 높은 비용을 요구하는 수면다원검사를 수행하여야 한다. 따라서 실생활에서 낮은 비용으로 손쉽게 수면의 효율을 측정하는 가속도 센서가 내장된 손목 착용형 장비가 활용 가능한 방안으로 부각되고 있다. 하지만 가속도 데이터를 이용한 기존의 수면/비수면 구간 분류 방식은 개별 시점의 가속도 값만을 이용해 수면/비수면 상태를 구분하기 때문에 수면 중 간헐적 움직임과 비수면 중 미세한 움직임이 발생한 구간에서 오분류율이 높은 약점이 있다. 본 논문에서는 분류과정에서 인근 시점간의 SVM 분류기 스코어의 유사성을 고려하는 동적 분류기를 이용함으로써 앞에서 언급한 문제에 효과적으로 대처할 수 있음을 보인다. 제안하는 알고리즘의 실생활 적용가능 여부 판단을 위하여 50개 데이터 세트에 대해 구간 구분을 수행하여 정확도 88.9%, 민감도 88.9%, 특이도 88.5%의 결과를 얻었다.

Abstract

A sleep disorder is being recognized as one of the major health issues related to high levels of stress. At the same time, interests about quality of sleep are rapidly increasing. However, diagnosing sleep disorder is not a simple task because patients should undergo polysomnography test, which requires a long time and high cost. To solve this problem, an accelerometer embedded wrist-worn device is being considered as a simple and low cost solution. However, conventional methods determine a state of user to "sleep" or "wake" according to whether values of individual section's accelerometer data exceed a certain threshold or not. As a result, a high miss-classification rate is observed due to user's intermittent movements while sleeping and tiny movements while awake. In this paper, we propose a novel method that resolves the above problems by employing a dynamic classifier which evaluates a similarity between the neighboring data scores obtained from SVM classifier. A performance of the proposed method is evaluated using 50 data sets and its superiority is verified by achieving 88.9% accuracy, 88.9% sensitivity, and 88.5% specificity.

Keywords : 가속도 센서, 수면/비수면, 동적 분류기, 웨어러블 디바이스, 헬스 케어

I. 서 론

수면의 질을 평가하는데 가장 효과적인 방법은 수면 다원검사로서 뇌전도(EEG), 심전도(ECG), 안전도(EOG), 근전도(EMG)를 비롯해 비디오 촬영이 병행된다. 하지만 복잡한 장비들을 착용한 채 검사실에서 하룻밤을 자야 하는 불편함이 존재하며 검사 비용 역시

* 학생회원, *** 평생회원, 고려대학교 전기전자공학과
(Dept. of Electronic Engineering, Korea Univ.)

** 정회원, 고려대학교 영상정보처리학과
(Dept. of Visual Information Processing, Korea Univ.)

© Corresponding Author(E-mail: hsko@korea.ac.kr)

Received ; January 27, 2014 Revised ; May 27, 2015

Accepted ; June 1, 2015

부담스러울 수 있다. 이로 인해 일상생활에서 수면의 질을 평가할 수 있는 간단한 장비들이 제안되었다. 그 중 심박 변이(HRV) 및 호흡 신호를 입력받을 수 있는 웨어러블 장비가 있지만^[1], 밴드 형태의 장비를 흉부에 착용해야 하므로 익숙하지 않은 사용자들의 수면 자체를 방해할 여지가 있다. 반면, **사용자의 활동량을 바탕으로 수면을 분석하는데 이용되는 가속도 측정 장치는 일반적으로 손목에 시계처럼 착용할 수 있다.** 따라서 데이터 수집과 정상적인 수면이 병행 가능하기 때문에 가장 널리 이용되는 방식이다^[2]. **입력받은 가속도 데이터를 이용해 수면의 패턴 및 수면 시간의 추정이 가능하지만,** 수면 패턴 분석의 경우 의료 전문가에 의한 수면다원검사가 병행되어야 하므로 본 논문에서는 다루지 않는다. **대신 본 논문에서는 가속도 데이터를 이용하여 하루 중 수면 및 비수면 시간을 추정하는 방법을 제안한다.**

가속도 데이터를 이용한 수면 및 비수면 시간 추정의 가장 기본적인 방식은 **임계치 기반과 회귀분석 기반 방식이다.** 전자는 일정 구간의 가속도 데이터의 가중 합의 크기가 임계값 보다 크면 비수면, 작으면 수면 상태로 분류하는 방식이다^[3]. 후자는 일정 구간에 대한 평균, 표준편차와 같은 특징 값들을 추출하고 마찬가지로 이들에 대한 가중 합의 크기에 따라 분류를 수행한다^[4]. 이후에 PIM (Proportional Integration Mode), ZCM (Zero Crossing Mode), TAT (Time Above Threshold) 와 같은 가속도 데이터의 특징 추출 방식이 제안되었고^[5], FFT (Fast Fourier Transformation) 를 이용한 주파수 대역의 특징 추출 방식도 이용되었다^[6]. 최근에는 SVM (Support Vector Machine) 과 같은 분류기의 학습을 통한 분류 방식 역시 제시되었다^[7].

위에서 언급한 방식들은 공통적으로 데이터의 특정 시점에 대한 상태 분류를 하는데 있어 오로지 해당 시점의 특징 값만을 고려한다. 만약 장비를 착용한 사람이 **수면 중에 순간적으로 크게 뒤척인다면 그 시점에 입력된 값은 깨어있는 상태에서 일반적으로 입력된 값과 차이가 적을 것이다.** 반대로 사용자가 깨어있는 상태에서 영화 감상이나 TV 시청 등의 이유로 잠시 동안 움직임이 거의 없다면 이 때 입력된 값은 수면 중 입력된 값과 그 양상이 다르지 않을 것이다. 따라서 해당 시점의 특징 값만을 가지고 분류를 수행하는 이전 방식들에서는 위와 같은 상황에서 수면 상태를 비수면 상태




그림 1. 제안 방식의 개요 (위: 학습 과정, 아래: 테스트 과정)

Fig. 1. Overview of the proposed method (top: training process, bottom: test process).

로, 비수면 상태를 수면 상태로 오분류할 가능성이 높다. 본 논문에서 이러한 분류 방식을 정적 분류 (static classification) 라고 칭한다.

반면 제안하는 동적 분류 (dynamic classification) 방식은 위와 같은 문제에 효과적으로 대응하기 위해 분류하려는 시점에 대해 **정적 분류기로부터 얻은 해당 시점의 스코어와 인근 시점의 스코어들과의 유사성을 고려하여 분류를 수행한다.** 예를 들어 동일 클래스의 연속된 데이터 x_1, x_2, x_3, x_4, x_5 가 있을 때 이에 대한 SVM 정적 분류기의 스코어들을 각각 $-1.5, -2, 0.2, -2.2, -0.9$ 라고 가정한다. 이 스코어들은 시그모이드 함수를 통해 최종적으로 $-1, -1, 1, -1, -1$ 의 클래스로 분류된다. 이 경우 x_3 은 나머지와 다른 클래스로 오분류된 것을 알 수 있다. 하지만 동적 분류 방식을 이용하면 분류 결과가 인접한 데이터들과의 시간 및 스코어의 유사성에 영향을 받으므로 x_3 을 나머지와 동일한 클래스로 분류할 수 있다.

제안하는 방식의 개요는 그림 1과 같다. 학습 단계에서 수면 및 비수면 상태의 가속도 데이터에 대해 전처리, 특징 추출, SVM 분류기 학습 과정을 거쳐 두 상태간의 분류 기준을 정한다.

테스트 단계에서는 검증하고자 하는 가속도 데이터에 대해 전처리, 특징 추출 과정을 거친 후 학습 단계에서 얻은 분류 기준을 이용해 입력 데이터의 각 시점에 대한 스코어를 얻게 된다. 이 스코어들은 동적 분류기를 거쳐 최종적으로 수면 상태 혹은 비수면 상태로 분류된다.

본 논문은 연구 주제와 관련한 배경 및 이슈 등을 다룬 서론, 제안하는 방식의 세부 사항에 대한 본론, 제안 방식의 효과 검증에 관한 실험, 연구 내용을 정리한 결론으로 구성된다.

II. 본 론

1. 가속도 측정 장비

본 연구에서 사용된 장비는 그림 2와 같이 3축 가속도 센서가 내장된 **손목 착용형태로 제작되었으며, 100Hz**의 표본 추출 비율을 갖는다. 본 장비는 시제품으로 기판이 외부에 노출되어있기 때문에 방수가 불가능하다. 시작 버튼을 누른 시점부터 종료 버튼을 누른 시점까지의 데이터가 장비에 저장되며 저장된 데이터는 케이블을 통해 PC로 전송되어 텍스트 파일로 변환된다.



그림 2. 손목 착용형 가속도 데이터 입력 장치
Fig. 2. wrist-worn accelerometer.

2. 전처리

전처리 단계에서는 센서로부터 입력받은 3축 가속도 데이터의 차원 축소 및 잡음, 아웃라이어 (outlier) 제거 과정을 통해 연산량을 줄이면서 수면 및 비수면 신호간의 구분성을 증가시킨다.

가. 가속도 데이터의 차원 축소

수면 및 비수면 상태 구분에는 사용자의 운동 세기와 운동 빈도를 고려할 뿐 방향성은 필요하지 않다. 따라서 3축의 가속도 신호를 종합하여 1차원의 Intensity 값으로 변환하면 분류에 필요한 정보를 보존하면서 연산량을 줄일 수 있다. 이 방식은 수식 (1)과 같이 나타낼 수 있다.

$$I_n = \sqrt{x_n^2 + y_n^2 + z_n^2} \quad (1)$$

I_n 은 n 번째 시점의 Intensity를, x_n, y_n, z_n 은 각각 n 번째 시점의 x 축, y 축, z 축 가속도를 의미한다.

나. 센서 잡음 제거

사용자의 움직임에 의해 얻어진 가속도와 함께 잡음 역시 입력 신호에 포함된다. 이 잡음 값은 실제 가속에

의한 입력 값에 비해 매우 작기 때문에 수면/비수면 구분에 영향을 적게 미친다. 하지만 본 논문에서 사용한 특징 추출 방법 중 하나인 ZCM (Zero Crossing Mode)의 경우 일정 구간 내에서 신호의 영교차 횟수를 특징 값으로 지정하고, 이 횟수의 많고 적음에 따라 상태를 분류하므로 이 경우에는 잡음이 수면/비수면 클래스간의 구분성을 떨어뜨리는 요인이 된다. 따라서 ZCM 특징 추출 전에 잡음을 제거할 필요가 있다. 앞에서 언급하였듯 잡음 값의 범위는 실제 입력된 가속도 값에 비해 매우 협소하다. 따라서 전체 입력 신호에 대한 windowing을 통해 잡음을 제거한다. 이 방법은 구체적으로 구간에 대한 표준편차가 특정 임계치 이하인 경우 사용자로부터의 가속도 신호가 입력되지 않은 상태로 가정하여 Intensity 값을 0으로 보정해주는 과정이며, 다음 수식 (2)와 같이 표현할 수 있다.

$$\hat{I}_n = \begin{cases} 0, & \text{if } \sigma > c_1 \\ I_n, & \text{otherwise} \end{cases} \quad (2)$$

위 수식에서 \hat{I}_n 은 잡음이 제거된 n 번째 시점의 Intensity를 의미한다. σ 는 해당 window 영역 내 Intensity 값들의 표준편차를 의미하며 c_1 은 특정 임계치를 의미한다. 본 연구에서는 c_1 값을 4로, window의 크기는 6000프레임으로 (60초) 지정한다.

다. 아웃라이어 제거

아웃라이어 제거 단계에서는 입력된 데이터의 흐름에서 벗어나 수면 및 비수면 구간에 대한 올바른 분류를 저해하는 일부 신호들을 제거하는 과정을 수행한다.

(1) 저역 필터 (Low pass filter)

저역 필터의 시간 축에서의 연산은 입력된 Intensity 신호를 부드럽게 (smoothing) 만드는 효과를 도출한다. 저역 필터는 MATLAB 내장 함수를 사용하였고 차수는 5, 차단 주파수는 2.5Hz로 설정하였다.

(2) 밀도 기반 필터

서론에서 언급한 가속도 데이터 구분의 어려움 중 하나인 수면 구간의 간헐적 움직임은 비교적 간단한 접근을 통하여 구분할 수 있다. 일반적으로 수면 구간 중 움직임은 수면 주기의 흐름에 따라 1~2시간 간격으로 발생하게 된다. 이 경우 움직임 전후로 정지 상태, 즉 센




그림 3. 가속도 데이터의 정지 상태 비율
Fig. 3. Stationariness rate of acceleration data.




그림 4. 전처리 과정을 거치기 전의 PIM 특징 값 (좌)과 전처리 후의 특징 값 (우)
Fig. 4. PIM feature values before (left) and after (right) pre-processing.

서에 가속도가 입력되지 않는 구간의 비율이 그림 3과 같이 매우 높게 나타난다. 이러한 특성을 이용하여 다음과 같은 필터링을 수행한다. 특정 구간의 정지 상태 대비 움직임 상태 비율이 임계치 c_2 (90% 이상) 를 초과하는 경우 이 움직임 상태를 아웃라이어로 정의하고 이를 주변 정지 구간의 Intensity 값인 0으로 대체한다. 여기서 특정 구간에 해당하는 window 크기는 4분으로 설정한다. 이 과정을 수식 (3)와 같이 표현하며 \hat{l}_n 은 필터링 과정을 거친 Intensity 값이다.

$$\hat{l}_n = \begin{cases} 0, & \text{if } \frac{\text{number of 0 value samples}}{\text{number of samples}} > c_2 \\ l_n, & \text{otherwise} \end{cases} \quad (3)$$

본 논문에서 제안하는 전처리 과정을 거치는 경우가 그렇지 않은 경우에 비해서 수면 구간과 비수면 구간에 대한 구분성이 더 우수한 특징을 추출하는 것을 아래 그림 4를 통해 확인할 수 있다.

3. 특징 추출

본 연구에는 100Hz로 데이터가 입력되는 장비를 사용하였다. 이 경우 데이터의 크기 문제로 실시간 처리가 어려우며 초 단위로 수면 및 비수면 상태를 구분하는 것 역시 현실적이지 못하다. 따라서 epoch (60초) 단

위에 대한 대표 특징 값을 추출함으로써 분류 성능은 유지하고 연산량은 줄일 필요가 있다. 다시 말해 60초 동안 입력된 6,000개의 샘플로부터 하나의 특징 값을 추출한다.

본 연구에는 총 3가지의 특징을 실험에 사용하였으며, 각 특징의 구분성 및 특징 조합들의 분류 성능을 비교함으로써 최적의 특징 조합을 찾았다.

가. 개별 특징 설명

(1) PIM (Proportional Integration Mode)

Intensity 값이 입력되었을 때 epoch 구간에 대한 넓이를 계산하여 얻는 값이며, 움직임의 크기 정도를 의미한다.

(2) ZCM (Zero Crossing Mode)

Epoch 구간에서 가속도 파형이 0의 값을 가로 지른 횟수를 나타내며 움직임의 빈도를 표현한다.

(3) FFT (Fast Fourier Transform)

Intensity 값을 주파수 영역으로 변환한 특징으로 단일 epoch 에서 나타나는 움직임 패턴의 구성을 표현하는데 적합한 특징이다. 일반적인 사람의 움직임은 2초 이내에서 발생하기 때문에 FFT window는 2초 (200 샘플) 로 설정하였다. 그리고 총 512개의 bin을 사용하였으나 전처리 과정에서 low pass filter를 이용하였기 때문에 DC 성분에 인접한 23개의 FFT coefficient만을 사용하였다. 23개의 coefficient가 1개의 epoch (60초) 에서 30회 얻어지기 때문에 23개 각각의 bin에 대한 표준편차 (23차원) 및 최대값을 (23차원) 최종 특징으로 사용하였다. (총 46차원)

나. 단일 특징 분석

수면/비수면 분류에 보편적으로 사용하는 3개의 특징에 대하여 개별 클래스 데이터의 표준편차와 클래스간 데이터의 평균 사이 거리를 통해 각 특징이 갖는 구분성을 표 1과 같이 확인하였다. 실험 데이터는 III. 실험의 데이터와 동일하며 (41명으로부터 얻은 50개 데이터 세트), 각 특징들의 추출 방식은 '가. 개별 특징 설명'에서 명시한 것과 같다. 표준편차는 수면 및 비수면 각 구간의 샘플이 얼마나 한 점에 몰렸는지를 나타낸다. 클

표 1. 단일 특징 분석 결과
Table 1. Result of single feature analysis.

특징	PIM		ZCM		FFT	
상태	수면	비수면	수면	비수면	수면	비수면
표준편차	0.114	0.031	0.040	0.218	0.125	0.018
클래스간 거리	0.0401		0.1335		0.0519	

래스간 거리는 두 클래스의 샘플 분포의 중심이 얼마나
떨어져있는지를 의미하는 것으로 특징 자체의 평균값
으로 오해해선 안 된다. 즉, 표준편차가 작고 클래스간
거리가 클수록 구분성이 큰 특징이다. 총 3가지 특징에
대하여 표준편차와 클래스간 거리를 측정한 결과 PIM
과 FFT는 유사한 표준편차를 보였고 ZCM은 비수면
클래스에 대해 큰 표준편차를 보였다. 반면 ZCM, FFT,
PIM 순으로 클래스간 거리가 측정되었다. 수면 보다
비수면 샘플들의 표준편차가 낮게 나온 이유는
Intensity의 샘플 분포가 주로 0 값 근처에 밀집되어있
기 때문인 것으로 판단된다. PIM, FFT, ZCM 특징의
분석 결과 유사한 값을 보였기 때문에 분류 결과를 확
인해 최적의 특징 조합을 정한다.

4. 구간 분류

구간 분류 단계는 정적 분류, 동적 분류 순으로 구성
되며, 정적 분류에서는 기계학습 분야에서 널리 사용되
고 있으며 수면/비수면 분류에도 활용되는 SVM
(Support Vector Machine) 분류기를 사용한다^[7]. 다음
단계인 동적 분류에서는 spectral clustering 방법을 이
용한다^[8]. 개략적으로 설명하면 이전 단계에서 얻은 특
징 조합을 SVM 분류기에 입력하여 **epoch별 스코어를**
얻는다. 이 스코어를 동적 분류기에 입력하여 최종적으
로 epoch의 상태를 수면 또는 비수면으로 분류한다.

가. 정적 분류

각 epoch의 특징 값들에 대해 RBF (Radial Basis
Function) kernel을 이용한 SVM 분류기를 사용한다^[9].
SVM 분류기는 MATLAB 내장 함수를 사용하였으며
파라미터들은 default 값으로 사용하였다. SVM 분류기
는 개별 epoch의 특징 값만을 이용해 분류를 수행하는
정적 분류기에 해당한다. 따라서 수면 중 간헐적 움직
임과 비수면 중 미세한 움직임이 나타나는 epoch를 오




그림 5. SVM 분류기의 결과
Fig. 5. Classification result of SVM.

분류하는 문제가 있다. 이로 인해 epoch의 상태에 대한
분류 성능이 떨어지며 정확한 수면 및 비수면 구간의
검출이 어려워진다. 따라서 본 연구에서는 SVM 분류
기로부터 얻은 epoch별 스코어를 동적 분류기의 입력
데이터로 사용해 추가적인 분류 과정을 거친다.

그림 5의 검은색 신호는 입력 가속도의 상대적 크기
를 나타내며 **파란색 선은 ground truth (0: 수면, 1: 비수면)를 표현한다.** 분홍색 점은 SVM이 비수면 상태로
분류한 epoch이고, 녹색 점은 수면 상태로 분류한
epoch이다. **수면 중 간헐적 움직임에 의해 ground truth가 0 인 (수면) 지점이 비수면 상태로 (분홍색) 오**
분류되었고, 비수면 중 미세한 움직임에 의해 ground truth가 1인 (비수면) 지점이 수면 상태로 (녹색) 오분
류되었다.

나. 동적 분류

정적 분류기의 개별 epoch간 스코어 차이와 epoch
간 거리를 평가해 최종 분류 결과를 얻는다. 예를 들어
수면 구간 안에서 정적 분류기는 특정 epoch를 비수면
상태로 오분류하더라도 동적 분류기는 주위 epoch 들과
의 스코어 및 거리적 유사성을 고려해 해당 epoch를
수면 상태로 바르게 분류할 수 있다. 구체적으로는
epoch간 거리 및 SVM 분류기의 스코어 값을 통해 유
사 행렬 (similarity matrix) A 를 상정하고 이를
k-means algorithm 기반 spectral clustering 기법을 통
해 분류한다.

$$A(i, j) = \exp\left(-\frac{d_{score(i, j)}^2}{2\sigma_{score}}\right) + \alpha \exp\left(-\frac{d_{epoch(i, j)}^2}{2\sigma_{epoch}}\right) \quad (4)$$

수식 (4)와 같이 유사 행렬을 설계한다. $d_{score(i, j)}^2$ 와
 $d_{epoch(i, j)}^2$ 는 각각 i 번째 epoch와 j 번째 epoch 사이의

SVM 분류기의 스코어 차이와 $(\sqrt{(score_i - score_j)^2})$ epoch간의 거리를 $(\sqrt{(i-j)^2})$ 뜻한다. $d^{score}(i, j)$ 의 경우 이 값을 구하기 전에 스코어가 $[-1, 1]$ 의 범위 내에서 값을 갖도록 제한한다. SVM 스코어의 절대 값이 클수록 해당 클래스에 매칭될 확률이 높다는 것을 의미하는데, 그러한 값들끼리의 거리 차가 발생하여 similarity가 낮게 책정될 경우를 방지하기 위해서이다. 그래서 SVM 스코어가 1 이상인 경우는 모두 1로, -1 이하의 값인 경우에는 -1로 지정한다. α 는 epoch간의 거리에 대한 exponential 함수의 가중치로서 실험을 통해 얻은 최적의 값 1400을 사용하였다. σ_{score} 와 σ_{epoch} 는 exponential 함수들의 감쇠 정도를 정하며 본 실험에서 σ_{epoch} 는 20, σ_{score} 는 1 값으로 정하였다. 이를 통해 얻은 행렬 A 를 각 행에 대한 총합 값을 이용해 정규화를 수행한다^[8].

$$L = D^{-1/2}AD^{-1/2} \quad (5)$$

행렬 D 는 행렬 A 의 각 행에 대한 총합 값을 대각 행렬로 만든 것이다. 수식 (5)에 해당하는 행렬 연산에 의한 정규화는 실제 구현에서 수식 (6)와 같이 표현 할 수 있다. 행렬 L 의 고유벡터를 추출하고 고윳값이 큰 순서대로 상위 2개의 고유벡터로 구성된 행렬 X 를 구성한 후 행에 대해서 정규화를 수행한다.

$$Y_{ij} = X_{ij} / (\sum_j X_{ij}^2)^{1/2} \quad (6)$$

수식 (6)의 행렬 Y 의 행을 하나의 특징으로 보고 k-means 알고리즘을 통해 2개의 클래스로 나눈다. 이때 나누어진 결과가 수면과 비수면 분류 결과가 된다. 아래의 그림 6은 정규화된 유사 행렬과 고윳값이 큰 순서대로 상위 2개의 고유벡터와 고윳값으로 복원한 결과이다.

그림 6의 복원 행렬을 보면 알 수 있듯 추출한 고유




그림 6. 정규화된 유사 행렬 (좌) 과 복원 결과 (우)

Fig. 6. Normalized similarity matrix (left) and reconstruction result (right).

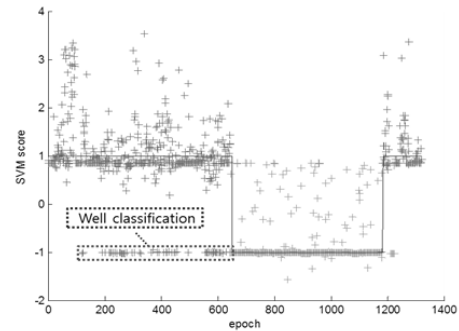


그림 7. Spectral clustering 분류 결과

Fig. 7. Classification result of spectral clustering.

벡터가 각각 수면과 비수면의 값을 크게 하는 방향으로 되어있다. 고유벡터의 특성에 의해 이 둘은 서로 직교한다. 가장 큰 고윳값을 갖는 고유벡터만으로도 클러스터링이 가능하지만, 서로 직교한 벡터의 성분들에 대한 클러스터링을 통한 구분이 더 잘 되도록 하였다.

그림 7은 그림 5와 동일한 입력 신호에 대해 SVM 스코어를 이용한 spectral clustering 결과를 보여준다. 파란색 선은 ground truth (-1: 수면, 1: 비수면)를 표현한다. 각 점들은 epoch별 SVM 스코어 값이며, 분홍색 점은 동적 분류기가 비수면 상태로 분류한 epoch이고 녹색 점은 수면 상태로 분류한 epoch이다. ground truth가 -1인 (수면) 지점에서 스코어가 0보다 큰 epoch들이 있지만 수면 상태로 바르게 분류되었다. 마찬가지로 ground truth가 1인 (비수면) 지점에서 스코어가 0보다 작은 epoch들이 있지만 비수면 상태로 바르게 분류되었다. 그림 5의 정적 분류 결과와 비교하여 제안한 방법이 수면구간 중 큰 움직임이 있는 구간, 비수면 구간 중의 움직임이 약한 구간을 잘 분류해내는 것을 알 수 있다.

III. 실험

본 연구를 통해 달성한 정량적 성능지표는 관련 논문에서 주로 사용되는 정확도 (accuracy), 민감도 (sensitivity), 특이도 (specificity) 총 3가지이다. 각각의 성능지표는 전체 구간, 수면 구간, 비수면 구간의 epoch당 분류 결과와 ground truth간의 일치율을 의미하며 수식 (7)~(9)과 같이 표현 할 수 있다^[10].

$$Accuracy(\%) = \frac{\text{number of true sleep epoch} + \text{number of true wake epoch}}{\text{number of all epoch}} \quad (7)$$

$$Sensitivity(\%) = \frac{\text{number of true sleep epoch}}{\text{number of all sleep epoch}} \quad (8)$$

$$Specificity(\%) = \frac{\text{number of true wake epoch}}{\text{number of all wake epoch}} \quad (9)$$

이 성능 지표들에 대한 실험 결과를 얻기 위해 먼저 실험 데이터의 ground truth 확보가 필요하다. 수면다원검사의 경우 전문의가 생체 신호를 분석하여 수면 및 비수면 구간을 분류하지만, 본 연구에서는 가속도 센서가 내장된 장비를 착용한 피험자가 수면 직전, 기상 직후의 시간을 직접 기록하는 방식으로 수면 구간과 비수면 구간의 ground truth를 정한다. 그렇기 때문에 수면다원검사에서는 각종 생물학적 신호에 의해 수면 중 깨어있는 상태로 판단되는 구간이 있을 수 있지만 본 연구에서는 피험자가 잠에서 깨어나 이 시간을 기록하지 않는 이상 수면 상태가 계속 이어지는 것으로 여겨진다. 따라서 전자에 비해 ground truth의 신뢰도가 떨어질 수밖에 없다. 또한 기판이 노출된 장비의 특성상 피험자가 샤워 시에는 장비를 탈착해야만 한다. 샤워에 대한 수기는 데이터 수집 당시 피험자에게 요구하지 않았기 때문에 대략 10~20분의 샤워 시간에 대한 ground truth는 올바르지 않다. 즉, 실제로는 비수면 구간이지만 센서가 탈착된 상태라 입력 신호는 수면 구간의 신호와 유사하다. 실제로 샤워 시간을 알고 있는 데이터에 대해 이 구간을 제거하고 성능을 측정한 결과 제거 이전 보다 3%의 정확도 지표의 성능 향상을 확인할 수 있었다. 따라서 방수가 가능한 장비를 사용하거나 피험자가 샤워 시간까지 기록한 데이터 세트를 실험에 이용할 경우 더 나은 성능을 보일 것이다. 이와 같은 방식으로 41명으로부터 수집된 총 50개의 데이터에 대하여 제안하는 알고리즘의 성능을 확인하였다. 50개의 데이터 중 45개는 20대~30대 정상(수면 장애가 없는) 남성 36명 피험자들로부터 수집한 것이며 나머지 5개는 5명의 30대 정상 여성들로부터 얻은 것이다. 모든 데이터의 평균 측정 시간은 16시간 23분이며 평균 수면 시간은 6시간 28분을 기록하였다. 모든 피험자는 수면 전/후로 2시간 이상 센서를 착용하였다. 이상의 50개의 데이터에 대하여 17개 데이터를 분류기 학습에 사용하고 나머지로 테스트를 진행하는 교차검증을 통해 분류 결과를 산출하였다. 데이터 세트 내에 일부 피험자에 대해 1개 이상의 데이터가 존재하므로 이들의 데이터가 분류기 학습과 테스트에 모두

사용되는 것을 피하여 교차검증을 수행하였다. 본 실험에서 전처리, 특징 조합, 동적 분류기 각각의 효과에 대한 검증 실험 역시 수행하였다.

1. 전처리 여부에 따른 성능 평가

본 논문에서 제시한 전처리 방식들의 효과를 확인하기 위해 전처리 과정의 유무에 따른 분류 성능을 비교하였다. 표 2와 같이 제안하는 전처리 방식을 사용한 경우 더 높은 분류 성능을 확인할 수 있다.

표 2. 전처리 유무에 따른 분류 성능
Table 2. Classification performance according to pre-processing.

	전처리 사용	전처리 미사용
정확도(%)	88.94	84.55
민감도(%)	88.93	85.10
특이도(%)	88.54	83.82

2. 특징 조합에 따른 성능 평가

3가지 특징의 표준편차 및 클래스간 거리 값이 유사하기 때문에 다양한 조합에 대한 분류 결과를 분석하여 최적의 특징 조합을 확인한다. 먼저 각각 단일 특징에 대한 분류 결과를 확인한 후 다양한 특징 조합을 이용한 Hybrid 특징의 결과를 확인하였다. 그 결과 표 3과 같이 단일 특징에서 PIM과 ZCM은 높은 민감도를 갖지만 이에 비해 상당히 낮은 특이도를 나타냈다. 반면 FFT 특징은 세 가지 평가 항목에 대해 모두 고른 성적을 얻었다. FFT 단일 특징이 좋은 성능을 보이는 이유는 그림 8과 같이 신체의 움직임에 의한 가속도 정보가 일종의 impulse 형태의 신호로서 모든 주파수 대역에서 에너지가 발생하기 때문인 것으로 보인다. 한편, PIM-ZCM-FFT의 Hybrid 특징이 모든 특징 중에서 3가지 평가 지표에 대해 평균적으로 가장 높은 성능을 보였다. 아래 결과를 바탕으로 분류기에 입력되는 특징 조합 x 는 FFT(46차원), PIM(1차원), ZCM(1차원), 총 48차원의 특징으로 이루어진다.

$$x_{epoch} = [Max(F_{epoch,1}) \dots Max(F_{epoch,23}) Std(F_{epoch,1}) \dots Std(F_{epoch,23}) P_{epoch} Z_{epoch}] \quad (10)$$

수식 (10)에서 Max 는 특징 벡터의 최대치에 해당하며, Std 는 특징 벡터의 표준편차, $F_{epoch,n}$ 은 epoch 시점




그림 8. 신체 움직임에 대한 주파수 분석
Fig. 8. Frequency analysis for body movement.

표 3. 특징 조합에 따른 분류 성능
Table 3. Classification performance according to feature combination.

특징 조합	정확도(%)	민감도(%)	특이도(%)
PIM	84.62	98.05	74.11
ZCM	83.37	98.19	71.81
FFT	84.60	85.31	83.80
PIM-ZCM	86.45	97.92	77.24
PIM-FFT	85.29	92.44	79.43
ZCM-FFT	85.07	87.85	82.61
PIM-ZCM-FFT	88.94	88.93	88.54

에서 n 번째 bin의 FFT 특징 값들이다. P_{epoch} 과 Z_{epoch} 는 각각 epoch 시점에서 PIM과 ZCM의 특징 값을 의미한다.

3. 동적 분류 여부에 따른 성능 평가

최종 분류 결과는 표 4와 같다. 표를 보면 정적 분류 방식이 동적 분류 방식 보다 정확도와 특이도는 낮지만 민감도는 높은 것을 확인할 수 있다. 정적 분류 방식을 사용하면 작은 스코어 값을 갖는 epoch 모두를 수면 구간으로 분류하기 때문에 높은 민감도를 얻을 수 있다. 하지만 비수면 중 미세한 움직임이 있는 구간마저도 수면 상태로 오분류하므로 상대적으로 낮은 특이도를 갖으며 따라서 정확도 역시 낮다. 정확도가 민감도와 특이도를 포괄하는 지표임을 감안할 때 제안하는 동적 분류 방식이 정적 분류 방식에 비해 높은 성능을 나타내는 것을 알 수 있다. 추가적으로 해당 연구 분야에서 널리 사용되는 방식들과의 비교 역시 수행하였다. Cole^[3]이 제안한 방식은 현재 epoch의 단일 특징(최대 또는 평균값)을 A_0 라 할 때 $A_{-4} \sim A_2$, 총 7프레임의 데이터에 대한 가중합이 임계치보다 크면 비수면, 작으면 수면 상태로 분류한다. Sadeh^[4]의 방식은 epoch 내 데이

표 4. 동적 분류 방식과 정적 분류 방식의 성능 비교
Table 4. Performance comparison between dynamic and static classification method.

	제안 방식 (동적 분류)	이전 방식 (정적 분류)	Sadeh ^[4]	Cole ^[3]
정확도 (%)	88.94	87.86	67.28	63.54
민감도 (%)	88.93	92.39	68.86	58.71
특이도 (%)	88.54	83.93	66.91	67.64

터의 평균, 표준편차, 최소값 등 다수의 특징들의 가중합과 임계치와의 비교를 통해 해당 구간의 상태를 분류한다. 이 방식들은 1차 분류 결과를 보정하는 동적 분류 과정이 없기 때문에 수면 중 간헐적 움직임, 비수면 중 미세한 움직임이 나타나는 구간에 대한 높은 오분류율로 인해 평균적으로 낮은 분류 성능을 보였다.

IV. 결 론

본 연구는 가속도 데이터를 이용한 수면/비수면 구간 분류 알고리즘에 관한 것이다. 수면 중 간헐적 움직임, 비수면 중 미세한 움직임이 나타나는 구간의 정확한 구분이 전체 분류기를 설계하는데 가장 큰 비중을 차지하였다. 구체적으로 수면 중 **간헐적 움직임으로 인한 문제는 움직임 밀도 기반의 필터링 방법으로 해결하였**으며, **비수면 중 미세 움직임으로 인한 문제는 최적의 특징 조합 결정 및 동적 분류기를 통해 해결**하였다. 실험적으로 제안하는 알고리즘은 50개의 데이터 세트에 대하여 88.9%의 정확도, 88.9%의 민감도, 88.5%의 특이도를 얻을 수 있었다.

REFERENCES

- [1] A. M. Bianchi and O. P. Villantieri et al, "Improving actigraph sleep/wake classification with cardio-respiratory signals", IEEE International Conference on Engineering in Medicine and Biology Society, pp. 3517-3520, New York, USA, August-September 2006.
- [2] A. Sadeh and C. Acebo, "The role of actigraphy in sleep medicine", *Sleep medicine reviews*, Vol. 6, no. 2, pp. 113-124, May 2002.
- [3] R. J. Cole and D. F. Kripke et al, "Automatic

- Sleep/Wake Identification From Wrist Activity”, *Sleep*, Vol. 15, no. 5, pp. 461-469, October 1992.
- [4] A. Sadeh and K. M. Sharkey et al, “Activity-based sleep-wake identification: an empirical test of methodological issues”, *Sleep*, Vol. 17, no. 3, pp. 201-207, April 1994.
- [5] G. Jean-Louis and D. F. Kripke et al, “Sleep estimation from wrist movement quantified by different actigraphic modalities”, *Journal of Neuroscience Methods*, Vol. 105, no. 2, pp. 185-191, February 2001.
- [6] W. Karlen and C. Mattiussi et al, “Improving actigraph sleep/wake classification with cardio-respiratory signals”, *IEEE International Conference on Engineering in Medicine and Biology Society*, pp. 5262-5265, Vancouver, Canada, August 2008.
- [7] A. H. Hokkanen and L. Hänninen et al, “Predicting sleep and lying time of calves with a support vector machine classifier using accelerometer data”, *Applied Animal Behaviour Science*, Vol. 134, no. 1-2, pp. 10-15, October 2011.
- [8] A. Y. Ng and M. I. Jordan et al, “On Spectral Clustering: Analysis and an algorithm”, *Advances in Neural Information Processing Systems*, Vol. 14, pp. 849-856, 2001.
- [9] S. Amari and S. Wu, “Improving support vector machine classifiers by modifying kernel functions”, *Neural Networks*, Vol. 12, no. 6, pp. 783-789, July 1999.
- [10] W. Karlen and D. Floreano, “Adaptive Sleep - Wake Discrimination for Wearable Devices”, *IEEE Transactions on Biomedical Engineering*, Vol. 58, no. 4, pp. 920-926, April 2011.

— 저 자 소 개 —



박 재 현(학생회원)-주저자
2011년 가톨릭대학교 디지털미디어 학부 공학사
2015년 현재 고려대학교 전기전자 공학과 석박사통합과정
<주관심분야 : 영상신호처리, 패턴 인식>



구 본 화(정회원)-공동저자
2000년 광운대학교 제어계측공학과 공학사
2002년 고려대학교 전자공학과 공학석사
2008년 고려대학교 영상정보처리학과 공학박사

<주관심분야 : 표적 탐지/추적, 데이터 융합>



김 대 훈(학생회원)-공동저자
2011년 고려대학교 전기전자전파 공학부 공학사
2015년 현재 고려대학교 전기전자 공학과 석박사통합과정
<주관심분야 : 영상신호처리>



고 한 석(평생회원)-교신저자
1982년 Carnegie-Mellon Univ. 전기공학 공학사
1988년 Johns Hopkins Univ. 전자공학 공학석사
1992년 Catholic Univ. of America 전자공학 공학박사

2015년 현재 고려대학교 전기전자전파공학부 교수

<주관심분야 : 영상/음성 신호처리, 패턴 인식>